



Project Group DS518-518

Project Title: End-to-End Automated Cloud-Based Credit Behavioral Scoring Pipeline

สมาชิกในกลุ่ม มีดังนี้

- | | |
|---------------------------|------------------------|
| 1. ชนกานต์ สมใจเพ็ง | รหัสนิสิต: 68199160260 |
| 2. นราวิชญ์ ธาราภูมิพัฒน์ | รหัสนิสิต: 68199160275 |
| 3. นฤกร เพ็งศรี | รหัสนิสิต: 68199160276 |
| 4. ศักดิธัช ฉั่นเฟื่องฟู | รหัสนิสิต: 68199160301 |

Project Title: End-to-End Automated Cloud-Based Credit Behavioral Scoring Pipeline
(ระบบประมวลผลคะแนนเครดิตเชิงพฤติกรรมแบบอัตโนมัติครบวงจรบนคลาวด์)

Business Scenario & Problem Statement

Business Scenario: Optimized Credit Risk Evaluation in Digital Banking

1. บทนำและที่มาของโครงการ (Project Overview & Rationale)

ธนาคารดิจิทัลให้บริการ Mobile Banking ที่ลูกค้าทำธุรกรรมจำนวนมากต่อวัน (โอนเงิน, จ่ายบิล, ซื้อสินค้า) ทีม Risk & Credit ต้องใช้ข้อมูลธุรกรรมเหล่านี้ เพื่อประเมินความเสี่ยงในการให้สินเชื่อ (เช่น อนุมัติบัตรเครดิต / สินเชื่อส่วนบุคคล) โดยใช้ Machine Learning model คำนวณ Behavioral Credit Score จากพฤติกรรมการใช้จ่ายของลูกค้า

ผู้ใช้ระบบหลัก:

Data Scientist — เทรน/ประเมิน credit scoring model

Credit Analyst — ดู dashboard score ของลูกค้ารายคน

Mobile Banking App — query ข้อมูลสรุปของลูกค้าแสดงในแอป

2. วิเคราะห์ปัญหาและแนวทางการแก้ไข (Problem Analysis & Solutions)

ปัญหาที่พบ	แนวทางแก้ไข
Data Quality: วันที่ที่ส่งมามีหลายรูปแบบและมีข้อมูลซ้ำ	ใช้ Pandas ใน Lambda แปลงวันที่ให้เป็นมาตรฐานเดียวและตัดข้อมูลซ้ำออก
Scoring Skewness: คะแนนกระจุกอยู่โซนสูงเกินไป แยกกลุ่มเสี่ยงไม่ออก	คำนวณคะแนนจากหลายปัจจัยพร้อมกัน โดยใช้ตัวหารที่สะท้อนพฤติกรรมจริงของลูกค้า
System Automation: รันด้วยมือเสี่ยงผิดพลาดและขึ้นกับคน	ใช้ EventBridge ตั้งเวลา ETL อัตโนมัติทุกคืน ไม่ต้องมีคนมาด
Observability: ไม่มีประวัติว่าข้อมูลไหลเข้าระบบเมื่อไหร่	บันทึก log ทั้งบนเครื่อง (CSV) และบน Cloud (RDS) ให้ตรวจสอบย้อนหลังได้


3. การออกแบบสถาปัตยกรรมนี้ตามแนวทาง Well-Architected

Pillar	How It Was Implemented
Process Automation	ใช้ EventBridge ตั้ง schedule อัตโนมัติทุกคืน ไม่ต้องรันด้วยมือ และบันทึก log ทั้งบนเครื่อง (CSV) และบน Cloud (RDS) ไว้ด้วย
Security	API Gateway รับข้อมูลจากภายนอกผ่าน HTTPS จุดเดียว Lambda ทำงานภายใน AWS ไม่เปิด endpoint ตรงสู่ภายนอก
Reliability	ไฟล์ที่ process แล้วย้ายเข้า archive ทันที ป้องกันค่านวนซ้ำ และ Lambda มี Retry อัตโนมัติเมื่อเกิดข้อผิดพลาด
Performance Efficiency	ทั้งระบบเป็น Serverless Lambda ปรับ capacity เองตามปริมาณข้อมูล ไม่ต้องแตะ server
Cost Optimization	Lambda คิดเงินเฉพาะตอนรัน ช่วงไม่มีข้อมูลไม่มีค่าใช้จ่าย ต่างจาก EC2 ที่เสียตลอด 24 ชั่วโมง
Sustainability	Serverless ใช้ทรัพยากรเฉพาะตอนจำเป็น ไม่มี idle server รันทิ้งไว้โดยไม่มีประโยชน์

ระบบถูกออกแบบบน AWS แบบ Serverless ทั้งหมด โดยใช้ EventBridge ตั้งเวลาให้ทำงานอัตโนมัติ โดยไม่ต้องกดรันเอง ข้อมูลจากภายนอกไหลเข้าผ่าน API Gateway จุดเดียวผ่าน HTTPS ทำให้ Lambda ที่ทำงานอยู่ภายในไม่ถูกเปิดเผยสู่ภายนอก เมื่อข้อมูลถูกประมวลผลแล้วจะถูกย้ายเข้า archive ทันทีเพื่อป้องกันการค่านวนซ้ำ และ Lambda มีกลไก Retry อัตโนมัติหากเกิดข้อผิดพลาด นอกจากนี้ยังบันทึก log ทั้งบนเครื่อง (CSV) และบน Cloud (RDS) ให้ตรวจสอบย้อนหลังได้ตลอด และเนื่องจากเป็น Serverless ทั้งหมด ระบบจึงปรับ capacity เองตามปริมาณข้อมูล จ่ายค่าบริการเฉพาะตอนที่ทำงานจริง ไม่มี server รันทิ้งไว้โดยไม่มีประโยชน์

4. แผนภาพสถาปัตยกรรมระบบ (Architecture Diagram)

Overall Architecture



Architecture Components

Component	บริการ AWS	หน้าที่
Client (sender.py)	-	Python script ในเครื่องผู้ใช้ ส่งไฟล์ JSON ผ่าน HTTPS POST
API Gateway	API Gateway (REST API)	จุดรับข้อมูลจากภายนอก ส่งต่อให้ Lambda 1
Lambda 1: CreditDataIngester	AWS Lambda	รับข้อมูล JSON แล้ว PutObject ลงโฟลเดอร์ raw/ ใน S3
S3 Bucket (Data Lake)	Amazon S3	คลังเก็บข้อมูลกลาง แบ่งเป็น 4 zone
EventBridge Schedule (00:00 ICT)	EventBridge	Trigger Lambda 2 อัตโนมัติทุกเที่ยงคืน
Lambda 2: CreditDataProcessor-Midnight	AWS Lambda	อ่านไฟล์ JSON จาก raw/ → Clean → เขียน CSV ลง processed/
EventBridge Schedule (00:05 ICT)	EventBridge	Trigger Lambda 3 อัตโนมัติหลัง Clean เสร็จ 5 นาที
Lambda 3: Credit-RDS-Aggregator	AWS Lambda	อ่าน CSV จาก processed/ → Aggregate + คำนวณ Score → UPSERT ลง RDS
RDS MySQL	Amazon RDS	ฐานข้อมูล 3 ตาราง: credit_feature_mart, credit_score_history, data_load_logs
Looker Studio	Google BI Tool	Query ข้อมูลจาก RDS มาแสดงเป็น Dashboard

5. รายละเอียดการประมวลผลข้อมูล (Data Pipeline Logic)

5.1 Data Cleaning & Pre-processing

ก่อนนำข้อมูลไปคำนวณ Lambda (Data-Processor) จะทำการ Clean Raw data ก่อน 3 ขั้นตอน

- **Timestamp Normalization:** วันที่ที่ส่งมามีหลายรูปแบบ (DD/MM/YYYY, ISO ฯลฯ) แปลงให้เป็น YYYY-MM-DD HH:MM:SS ทั้งหมด
- **Deduplication:** ตรวจสอบ `txn_id` ซ้ำแล้วตัดทิ้ง ป้องกันยอดเงินบวกเกิน
- **Currency Conversion:** แปลง USD/JPY เป็น THB ตามอัตราแลกเปลี่ยนก่อนนำไปคำนวณ

5.2 Feature Engineering: Behavioral Scoring Model

คะแนนถูกคำนวณจาก 4 ปัจจัย โดยให้น้ำหนักต่างกันตามความสำคัญ

1. **Financial Stability (40%):** ดูจาก `total_spent_thb` เทียบกับ 500,000 THB
2. **Lifestyle Diversity (30%):** ดูจาก `distinct_categories` เทียบกับ 10 หมวดหมู่
3. **Financial Consistency (20%):** ดูจาก `txn_count` เทียบกับ 150 รายการ
4. **Purchasing Power (10%):** ดูจาก `avg_ticket_size` เทียบกับค่าเฉลี่ยกลุ่มตัวอย่าง

นอกจากนี้ยังมีการคำนวณ Essential Spending Ratio เพื่อแยกแยะสัดส่วนค่าใช้จ่ายจำเป็น ซึ่งเป็นตัวชี้วัดสำคัญของ "ความสามารถในการชำระหนี้" (Debt Serviceability)

6. การออกแบบฐานข้อมูล (Relational Database Schema)

ใช้ Amazon RDS (MySQL) เพื่อรองรับการทำ ACID Transactions โดยแบ่งเป็น 3 ตาราง

- **credit_feature_mart:** เก็บข้อมูลสถานะล่าสุดของลูกค้าแต่ละคน
- **credit_score_history:** เก็บประวัติคะแนนรายวัน ใช้ดู trend ใน Looker Studio
- **data_load_logs:** บันทึกว่าแต่ละไฟล์มีกี่ row เพื่อตรวจสอบความครบถ้วน

7. ผลลัพธ์และสรุป (Results & Conclusion)

- **High Efficiency:** ระบบเป็น Serverless ทั้งหมด ไม่มีค่าใช้จ่ายช่วงที่ไม่มีข้อมูลไหลเข้า และรองรับข้อมูลปริมาณมากได้โดยไม่ต้องปรับ server
- **Insightful Visualization:** Looker Studio แสดงการกระจายตัวของคะแนนแบบ Normal Distribution ทำให้ฝ่ายวิเคราะห์ความเสี่ยงแบ่งกลุ่มลูกค้าได้ง่ายขึ้น
- **Standardized Process:** pipeline ที่สร้างขึ้นสามารถนำไปต่อยอดกับ Machine Learning model ได้โดยไม่ต้องแก้โครงสร้างใหม่

Why These Services Were Chosen

Service	ทำไมถึงเลือก
AWS Lambda	ไม่ต้องดูแล server จ่ายเฉพาะตอนที่รัน เหมาะกับงานที่ทำตามเวลา ไม่ได้รันตลอด 24 ชั่วโมง
Amazon API Gateway	รับข้อมูลจากภายนอกผ่าน HTTPS ได้ทันที จัดการ security และ routing ในจุดเดียว โดยไม่ต้องเขียน server เอง
Amazon EventBridge	ตั้งเวลาให้ระบบทำงานอัตโนมัติได้โดยไม่ต้องเขียน script เพิ่ม และรองรับ retry อัตโนมัติ
Amazon S3	เก็บไฟล์ได้ไม่จำกัด ราคาถูก เหมาะกับการเก็บ raw และ processed data แบบ Data Lake
Amazon RDS MySQL	รองรับ ACID transaction ใช้ SQL query ข้อมูลได้ตรงตามที่ Looker Studio ต้องการ
Looker Studio	ใช้ฟรี ต่อตรงกับ MySQL ได้เลย ไม่ต้องติดตั้งหรือ setup เพิ่ม

- ทุก service ที่เลือกมาตอบโจทย์ธุรกิจการเงินโดยตรง ข้อมูล transaction ที่เข้ามาทุกวันถูก process อัตโนมัติด้วย Lambda และ EventBridge โดยไม่ต้องรันตลอด API Gateway ทำหน้าที่เป็นจุดรับข้อมูล จุดเดียวผ่าน HTTPS ซึ่งเป็นสิ่งที่ระบบการเงินต้องการ ข้อมูล credit score ถูกเก็บใน RDS MySQL ที่รองรับ ACID transaction ป้องกันข้อมูลหายหรือคำนวณผิด ส่วน S3 ใช้เก็บ raw data ปริมาณมากในราคาที่ไม่แพงก่อน process และ Looker Studio ให้ ดู dashboard ได้ทุกวันโดยไม่ต้อง setup ซ้ำซ้อน